NAMA	MATA KULIAH
Citra Putri Saragih | NIM 574147	Data Warehouse & Business Intelligence
DOSEN PENGAMPU	**STACK**
Rifki Afina Putri, S.T., M.S., Ph.D.	Apache Airflow • dbt Core • dbt-duckdb • DuckDB • Power BI

Ringkasan Hasil

TRANSAKSI DARI OUTPUT AIRFLOW	MASTER PRODUK	PENJUALAN BERSIH SELURUH KANAL
970	**90**	**Rp187,49 jt**

Mengapa data ini diproses lagi?

Output Airflow sudah melewati validasi awal. Tahap dbt kemudian memberi struktur transformasi yang lebih mudah diperiksa: sumber dinyatakan di YAML, pembersihan dipisah ke model staging, dan agregasi untuk kebutuhan bisnis ditempatkan di datamart. Power BI membaca tabel mart dari file DuckDB melalui konektor DuckDB; CSV yang tersedia di folder dashboard hanya berfungsi sebagai ekspor pendukung.

Pertanyaan yang diarahkan oleh dashboard

- **Kanal:** kanal mana yang berkontribusi paling besar pada penjualan bersih, dan seberapa jauh selisihnya dengan kanal lain?
- **Waktu:** bagaimana penjualan bersih berubah dari bulan ke bulan selama Januari–September 2026?
- **Kategori:** kategori produk mana yang memberikan penjualan bersih tertinggi pada kombinasi bulan, kanal, dan kota yang tersedia?

Alur kerja yang digunakan

01 AIRFLOW — validasi awal → **02** DUCKDB / RAW — simpan sumber → **03** DBT → POWER BI — mart dan visual

MODEL DESIGN

Keputusan transformasi di dbt

Model dipisah menurut pekerjaannya, bukan sekadar dibuat banyak: staging untuk konsistensi data, mart untuk pertanyaan analitik.

MODEL	SUMBER / RELASI	MATERIALISASI	FUNGSI UTAMA
stg_transactions	source(raw, transactions) → dipetakan melalui identifier ke raw.transactions_airflow	View	TRY_CAST dan NULLIF/TRIM untuk tipe serta string kosong; deduplikasi transaction_id; cek quantity, unit_price, rating, dan keberadaan product_id.
stg_products	raw.products	View	Standarisasi atribut produk, cast is_active, deduplikasi product_id, serta validasi ID, nama, dan harga.

mart_sales_analysis	ref(stg_transactions) + ref(stg_products)	Table	Agregasi menurut bulan, kategori, kanal penjualan, dan kota; menghasilkan jumlah transaksi, kuantitas, gross, diskon, shipping, net sales, dan average rating.

Mengapa materialisasinya berbeda?

- **Staging sebagai view.** Model staging menyimpan logika SQL tanpa membuat salinan tabel fisik terpisah. Ini memudahkan pemisahan aturan pembersihan dari hasil agregasi.
- **Datamart sebagai table.** Agregasi disimpan sebagai tabel agar dashboard dapat membaca hasil yang sudah diringkas tanpa menghitung ulang seluruh logika transformasi di setiap visual.

PERUBAHAN SUMBER YANG PENTING

Tabel fisik transaksi yang dipakai dbt adalah raw.transactions_airflow (970 baris). Dalam sources.yml, nama sumber logis tetap transactions dengan identifier: transactions_airflow. Ini menjaga model SQL tetap menggunakan source("raw", "transactions"), tetapi membaca output Airflow yang telah disiapkan.

Jejak dependensi model



Gambar 1. Lineage dbt: sumber raw mengalir ke staging, lalu ke mart; tes singular mengikuti stg_transactions.

Satu detail yang perlu dibaca dengan benar: node raw.transactions pada diagram adalah nama logis dbt. File database menyimpan sumber Airflow di raw.transactions_airflow karena pemetaan identifier dalam sources.yml.

QUALITY CHECK

Angka sebelum dan sesudah tiap lapisan

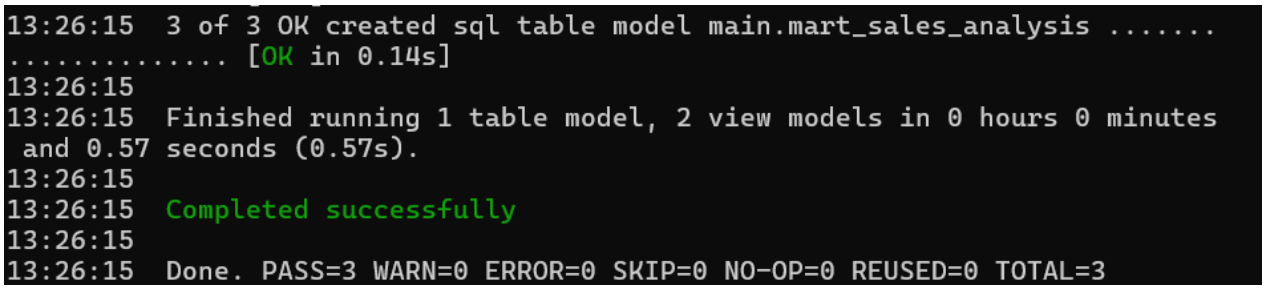
Perbandingan ini membedakan pekerjaan Airflow dari pekerjaan dbt. DBT menerima output Airflow yang sudah difilter, jadi angka staging tidak boleh diklaim sebagai pembersihan tambahan 30 baris.

LAPISAN	JUMLAH	CARA MEMBACA
CSV transaksi awal	1.000 baris	Masukan awal pada tugas Airflow.
Output Airflow: transformed_transactions.csv	970 baris	Airflow menghasilkan 970 transaksi valid; selisih 30 baris sudah ditangani di pipeline Airflow.
DuckDB: raw.transactions_airflow	970 baris	Salinan output Airflow yang dipakai dbt sebagai sumber transaksi.
DBT: stg_transactions	970 baris	Jumlah tetap sama pada eksekusi yang diverifikasi; model staging tetap menerapkan aturan cast/validasi.
Master produk / staging produk	90 / 90 baris	90 produk pada tabel sumber dan 90 pada stg_products.
mart_sales_analysis	713 baris, 11 kolom	Baris berisi kombinasi agregat bulan, kategori, kanal, dan kota; bukan 713 transaksi mentah.

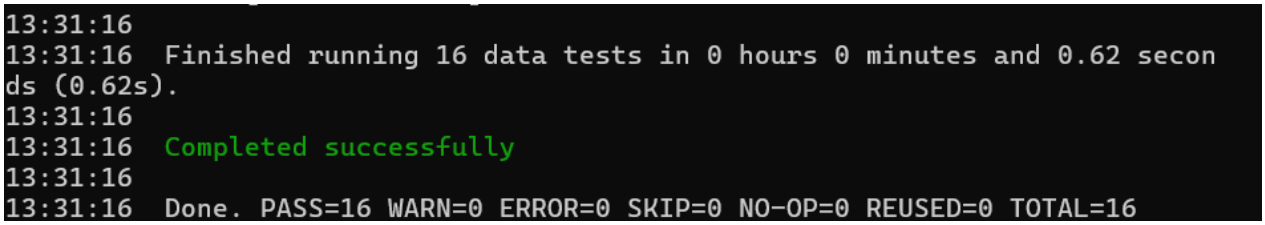
Apa yang diuji oleh dbt?

JENIS	RINGKASAN
15 generic tests	Aturan not_null dan unique pada kunci/atribut penting transaksi, produk, dan mart; termasuk transaction_id, product_id, tanggal, kuantitas, harga, serta kolom penting mart.
1 singular test	assert_valid_staging_transactions.sql memeriksa baris staging yang melanggar aturan validasi transaksi yang ditetapkan di SQL.
Hasil run terbaru	dbt run: 3 model PASS, 0 error. dbt test: 16 tests PASS, 0 error.

Bukti eksekusi terbaru



Gambar 2. Ringkasan dbt run: seluruh 3 model berhasil dibuat (PASS=3, ERROR=0).



Gambar 3. Ringkasan dbt test: 16 tes lulus tanpa error (PASS=16, ERROR=0).

Batas interpretasi: angka 970 berasal dari output Airflow dan menjadi input dbt. Enam belas tes yang lulus mengonfirmasi aturan yang didefinisikan pada data saat diuji, bukan seluruh kemungkinan isu kualitas.

BUSINESS READOUT

Apa yang ditunjukkan dashboard?

Power BI memakai mart dari DuckDB. Slicer kanal membantu membedakan total seluruh penjualan dan hasil saat hanya satu kanal dipilih.

Tampilan dengan filter Marketplace

Saat Marketplace dipilih pada slicer, KPI menampilkan penjualan bersih Rp66,17 juta, 362 pada metrik transaction_count, dan 623 unit pada total_quantity. Angka ini adalah hasil filter kanal, bukan total seluruh dataset.



Gambar 4. Halaman Ringkasan Penjualan dengan slicer Marketplace aktif; KPI ikut berubah mengikuti pilihan kanal.

Komposisi seluruh kanal

KANAL	NET SALES	PORSI	INTERPRETASI
Marketplace	Rp66,17 juta	35,29%	Kontributor terbesar pada data mart.
Mobile App	Rp58,80 juta	31,36%	Kontributor kedua.
Website	Rp38,55 juta	20,56%	Berada di urutan ketiga.
Social Commerce	Rp23,98 juta	12,79%	Kontribusi terkecil dari empat kanal.



Gambar 5. Halaman analisis kanal pada kondisi seluruh kanal: total penjualan bersih Rp187,49 juta.

PEMBACAAN BISNIS AWAL

Marketplace memberi kontribusi penjualan bersih paling besar, sedangkan Social Commerce paling kecil. Ini menunjukkan perbedaan kontribusi pada dataset yang dianalisis; angka ini sendiri belum cukup untuk menyimpulkan profitabilitas, biaya akuisisi, atau sebab perilaku pelanggan.

IMPLEMENTATION NOTES

Kendala nyata, solusi, dan cara mengulang hasil

Bagian ini mencatat langkah teknis yang memengaruhi keterulangan project ketika dibuka lagi atau dipindahkan ke komputer reviewer.

KENDALA	PENANGANAN / CATATAN
Sumber dbt sempat menunjuk tabel yang berbeda	Tabel raw.transactions dari CSV mentah tetap ada di database; agar proses lanjutan memakai hasil Airflow, sources.yml diatur dengan identifier: transactions_airflow. Setelah itu stg_transactions dijalankan ulang dan jumlah sumber/staging diperiksa.
Power BI tidak langsung mengenali DuckDB	Driver ODBC Windows dan konektor Power Query DuckDB (.mez) dipasang, lalu pengaturan Data Extensions di Power BI diizinkan untuk memuat konektor yang belum tersertifikasi. Setelah restart, DuckDB muncul di Get Data.
Dashboard awal masih membaca CSV	Tabel mart dimuat lagi melalui konektor DuckDB, kemudian field pada KPI dan visual utama diganti ke tabel warehouse mart. Total mart dicek dari SQL DuckDB dan cocok pada Rp187.494.000.
Lokasi database terikat ke laptop	File .pbix menyimpan jalur lokal WSL. Komputer reviewer harus memasang konektor dan menyesuaikan parameter database agar menunjuk ke file data/warehouse.duckdb pada lokasi lokalnya.

Menjalankan ulang model

Dari root repository, environment Python perlu diaktifkan terlebih dahulu. Kemudian jalankan perintah berikut dari folder dbt_project:

```
cd dbt_project
dbt debug --profiles-dir . --project-dir .
dbt run --profiles-dir . --project-dir .
dbt test --profiles-dir . --project-dir .
dbt docs generate --profiles-dir . --project-dir .
dbt docs serve --profiles-dir . --project-dir . --port 8081
```

Catatan untuk reviewer: profiles.yml menggunakan lokasi database relatif dari konteks dbt_project. Pastikan file data/warehouse.duckdb berada pada struktur folder yang sama. Untuk Power BI, koneksi memakai mode Import; artinya data dimuat dari DuckDB ketika proses load/refresh dijalankan dan bukan DirectQuery.

Kesimpulan dan pekerjaan lanjutan

Hasil project menunjukkan alur yang dapat dijalankan dari keluaran Airflow ke model dbt, dengan 3 model berhasil dibangun dan 16 tes lulus pada eksekusi terakhir. Mart menyediakan agregat untuk analisis waktu, kategori, kota, dan kanal; Power BI menggunakannya untuk menampilkan total serta perubahan berdasarkan slicer. Sebagai langkah lanjut, project dapat menambah incremental model, tetapi fitur itu belum diimplementasikan dan tidak diklaim sebagai hasil saat ini.

BATAS IMPLEMENTASI DAN LANGKAH BERIKUTNYA

Incremental model belum termasuk dalam versi ini. Jika dikembangkan, tambahkan model incremental, lalu buktikan perilaku run berikutnya dengan pengujian yang sesuai. Agar dashboard dapat dibuka di komputer lain, reviewer juga perlu memasang konektor DuckDB dan menyesuaikan path file database lokal.